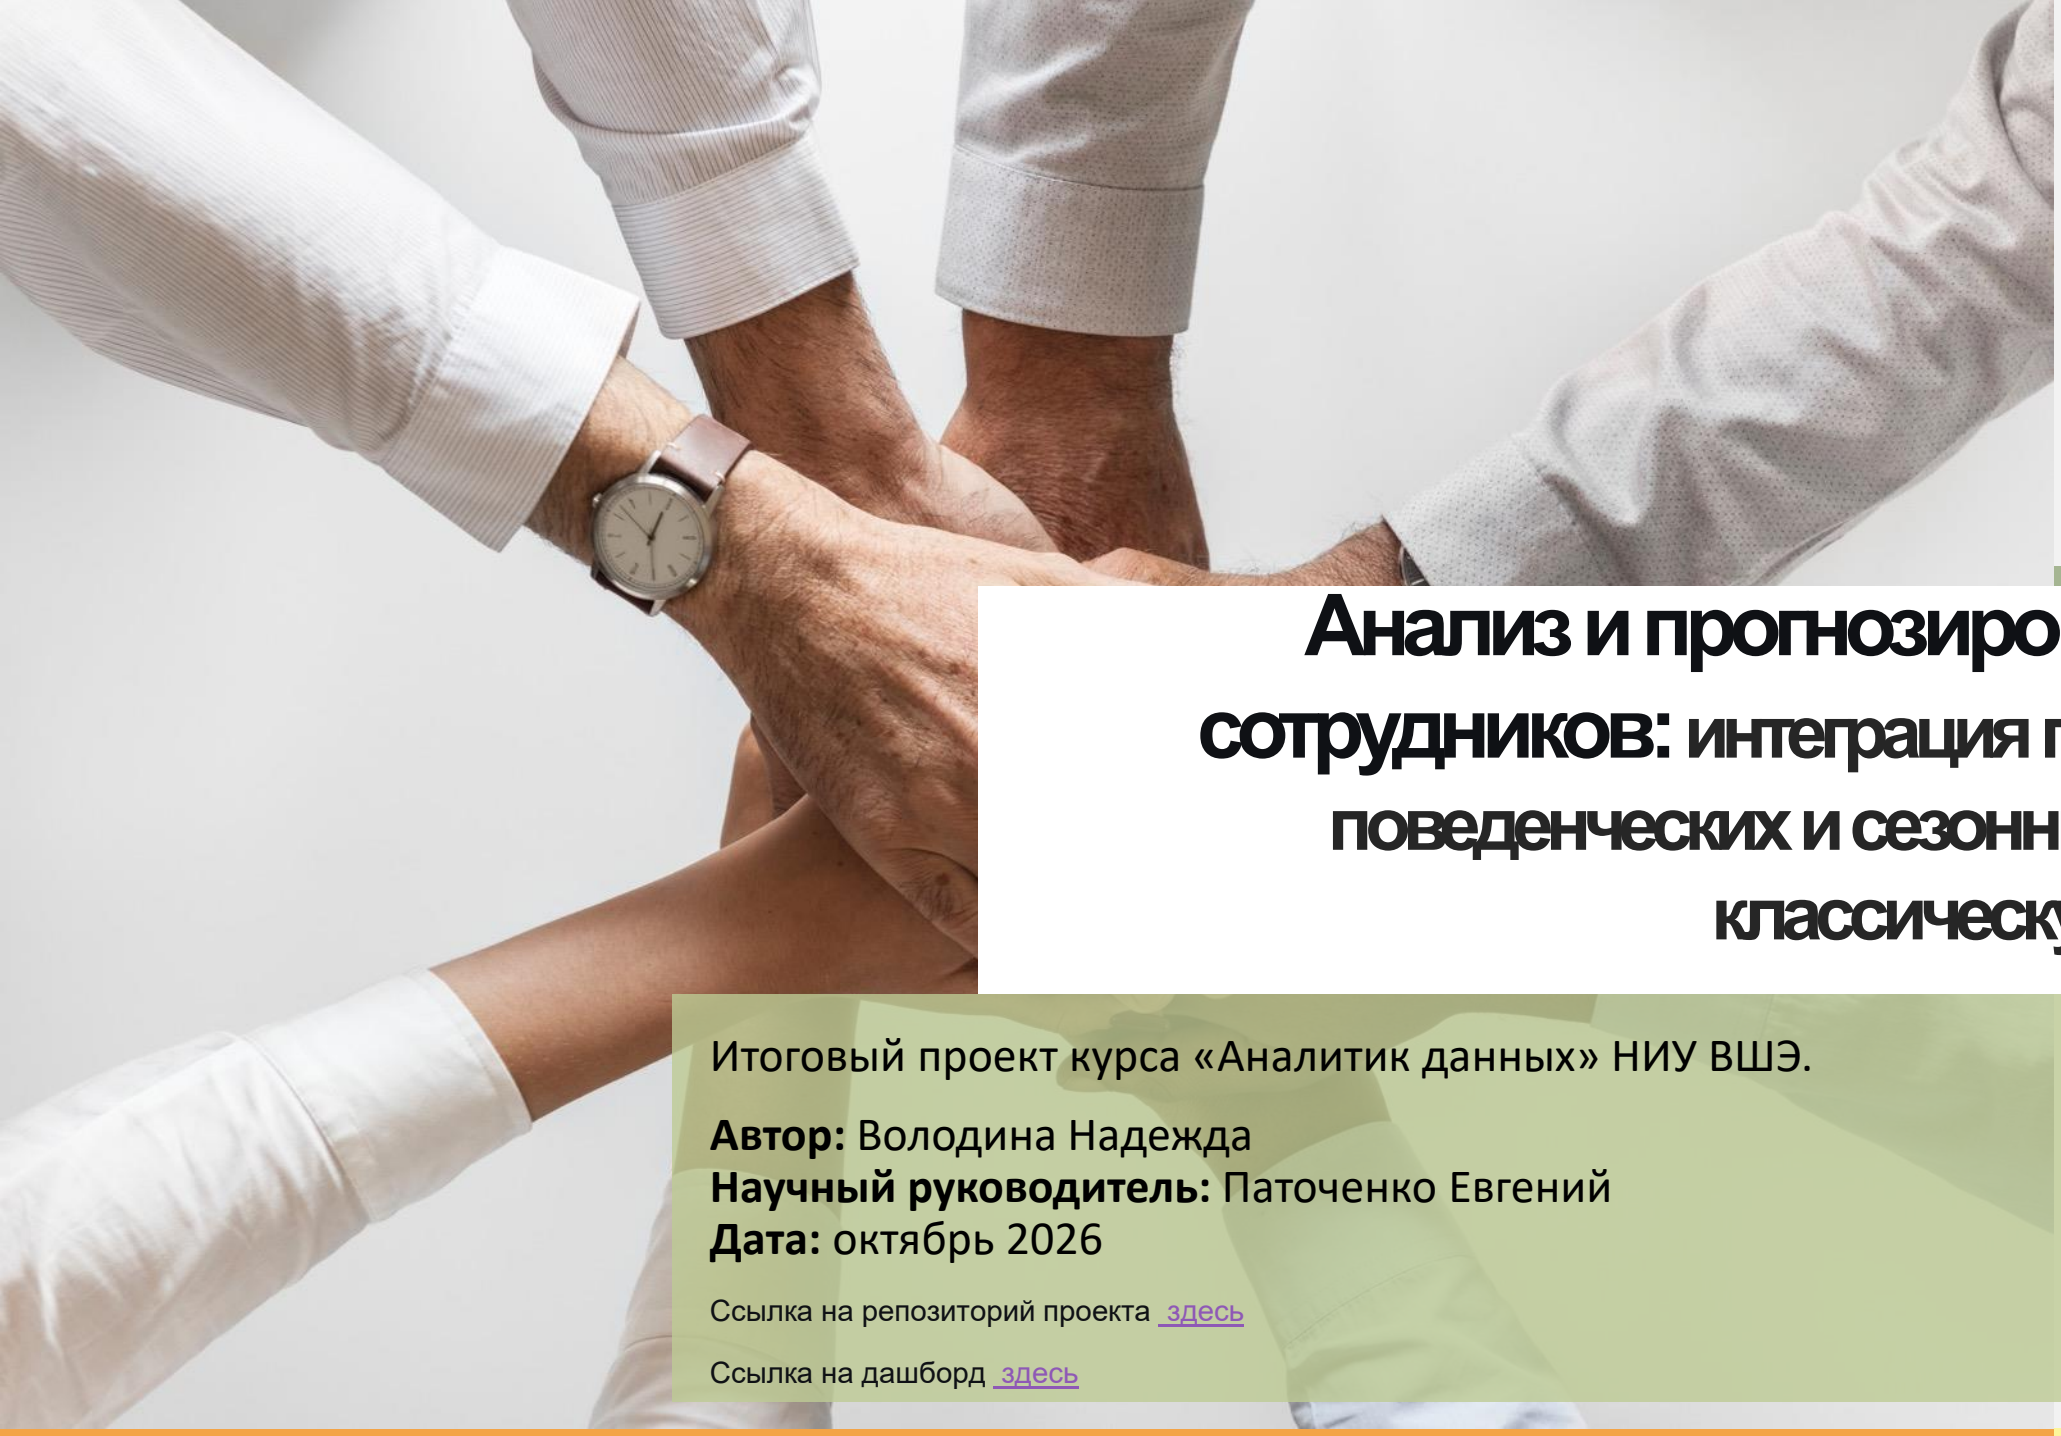


Анализ и прогнозирование оттока сотрудников: интеграция поколенческий, поведенческих и сезонных факторов в классическую HR-модель.

Итоговый проект курса «Аналитик данных» НИУ ВШЭ.

Автор: Володина Надежда
Научный руководитель: Паточенко Евгений
Дата: октябрь 2026

Ссылка на репозиторий проекта здесь

Ссылка на дашборд здесь

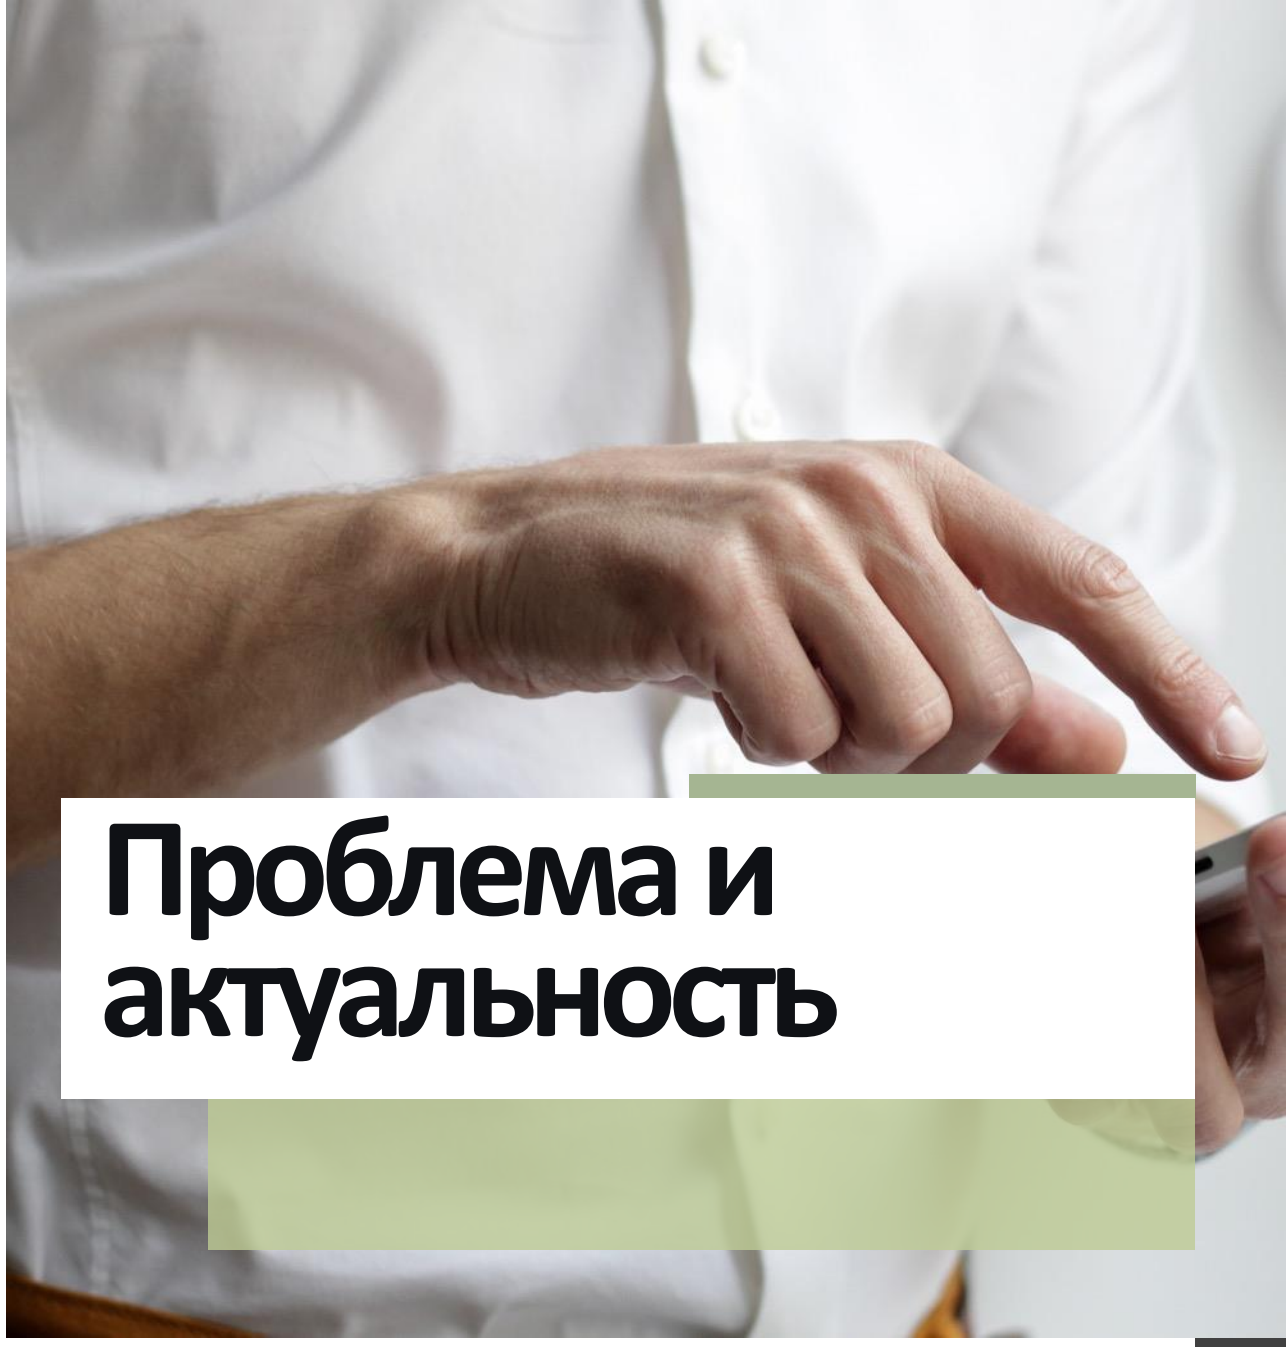


Основные задачи проекта

Проблема и актуальность

Почему это важно:

- **Отток сотрудников — дорого.** Замена одного сотрудника стоит 50-200% его годовой зарплаты.
- **Классические HR-модели устарели.** Учитывают демографию и зарплату, но не учитывают, как сотрудник себя чувствует.
- **Поколение Z выходит на рынок.** Их мотивация отличается от миллениалов и X.
- **Стоимость ошибки велика:** не найти уходящего = потерять ценного специалиста; найти «ложного уходящего» = потратить бюджет на удержание без причины.



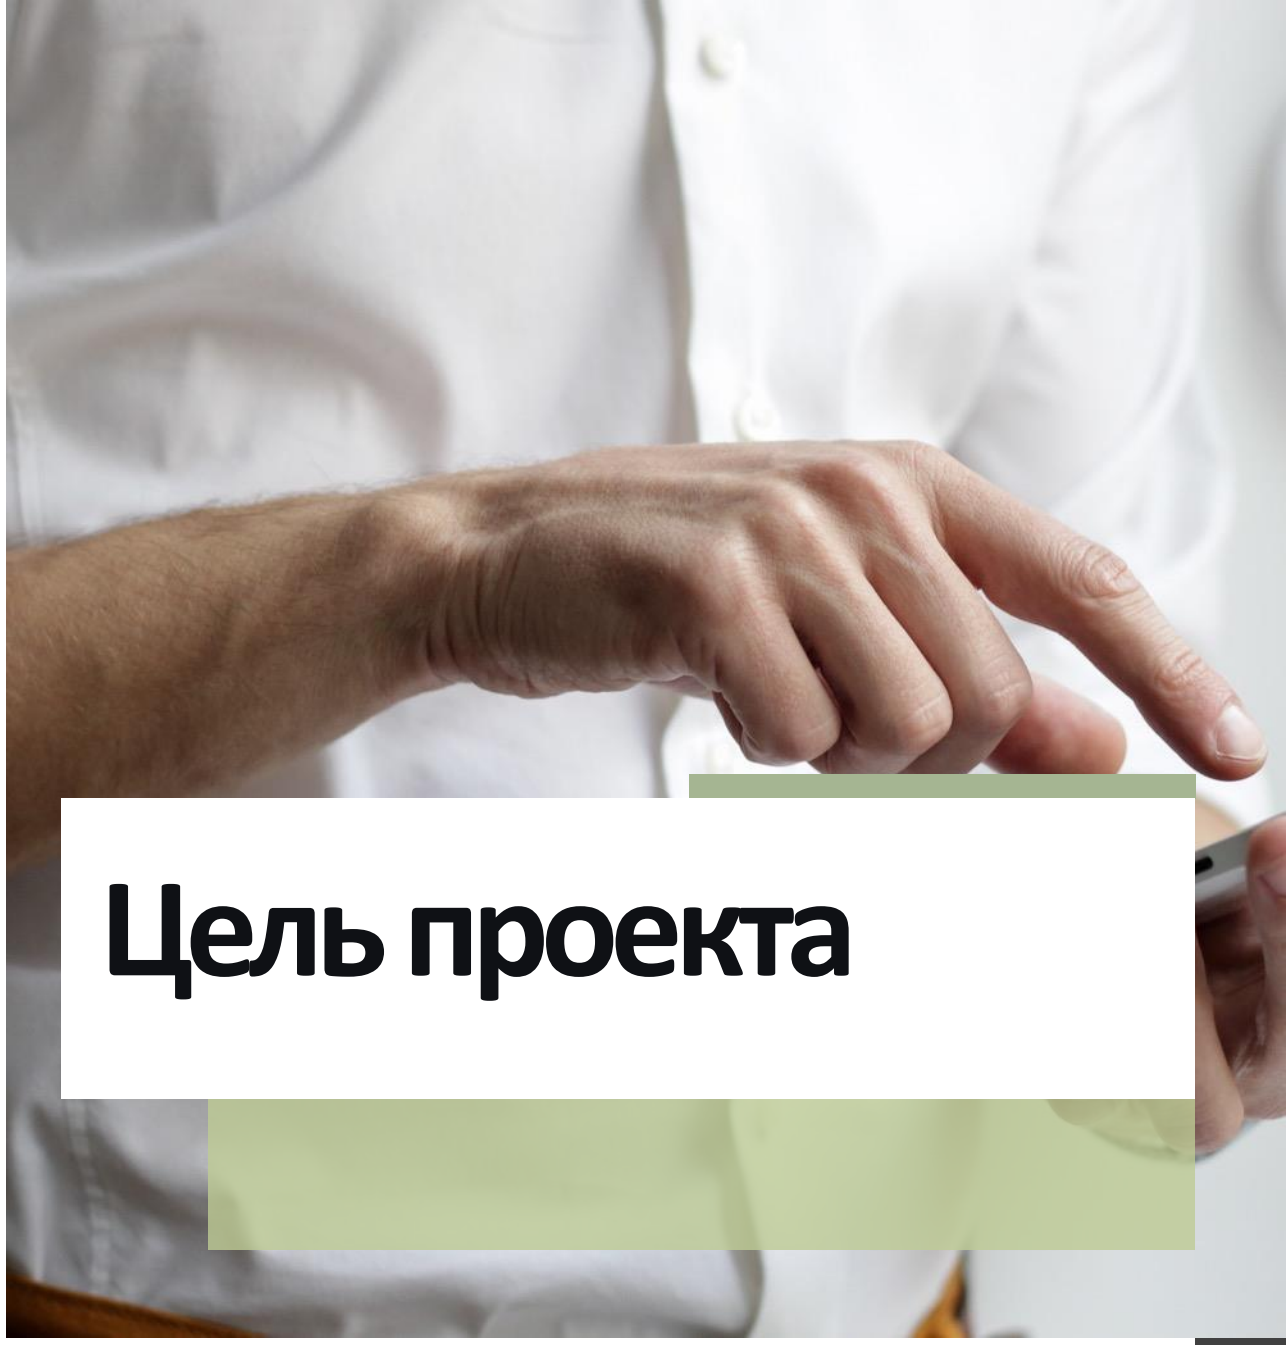
Цель:

Построить модель прогнозирования оттока, которая расширяет классический подход тремя слоями: поведенческим, поколенческим, сезонным.

Проверить, улучшают ли эти слои качество прогноза и делают ли модель более объяснимой.

Задачи:

1.Провести EDA и выявить закономерности
2.Создать новые признаки (Generation, Season_of_birth, Overall_Satisfaction)
3.Построить классическую и расширенную модели
4.Сравнить их качество
5.Сформулировать рекомендации для HR



Цель проекта



Данные



Данные

С чем имеем дело

Источник: HR-Employee-Attrition (Kaggle)

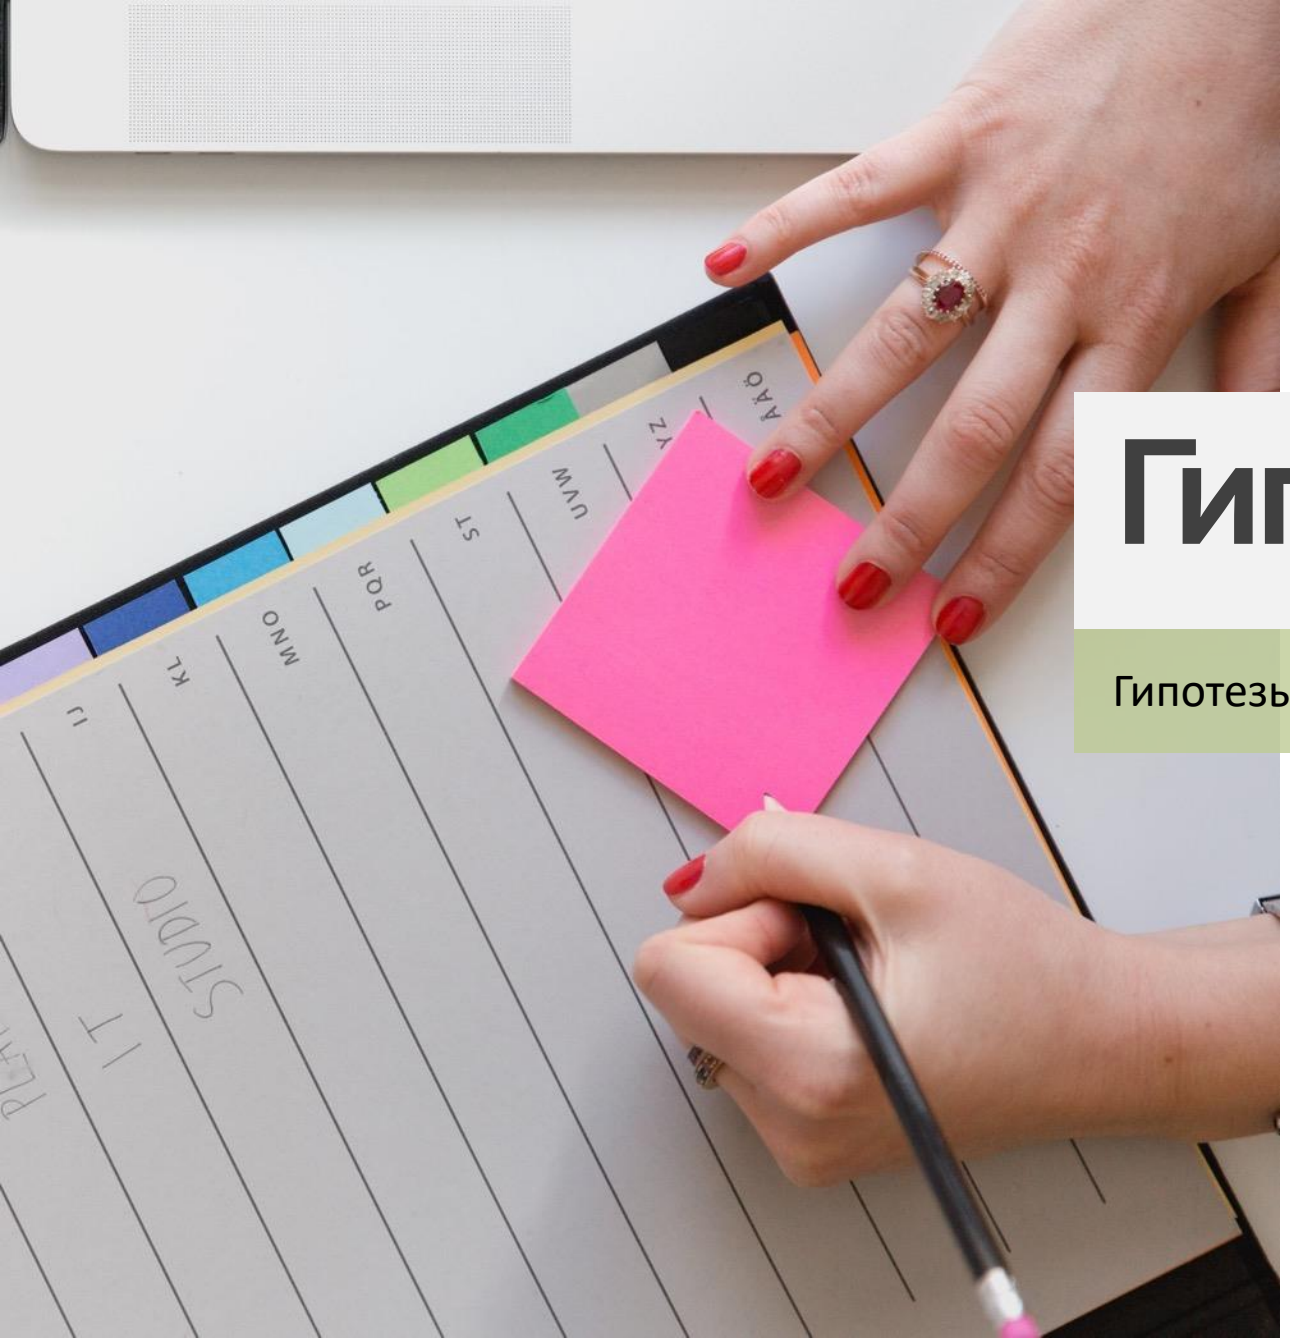
Размер: 1470 записей, 35 признаков

Целевая переменная: Attrition (Yes/No)

Дисбаланс классов: 16.1% ушедших / 83.9% оставшихся

Таблица групп признаков

Группа	Примеры
Демография	Age, Gender, MaritalStatus
Структура	Department, JobRole, JobLevel
Компенсация	MonthlyIncome, StockOptionLevel
Поведение	OverTime, JobSatisfaction, WorkLifeBalance
Стаж	YearsAtCompany, TotalWorkingYears



Гипотезы

Гипотезы, которые я проверяла

1. **Поколенческая:** поколение Z уходит чаще, чем X и Y
2. **Поведенческая:** низкая удовлетворённость и сверхурочная работа — сильные предикторы оттока
3. **Сезонная:** сезон рождения влияет на склонность к смене работы (проверяется как прокси)

Feature Engineering

Созданные признаки.

Таблица созданных признаков

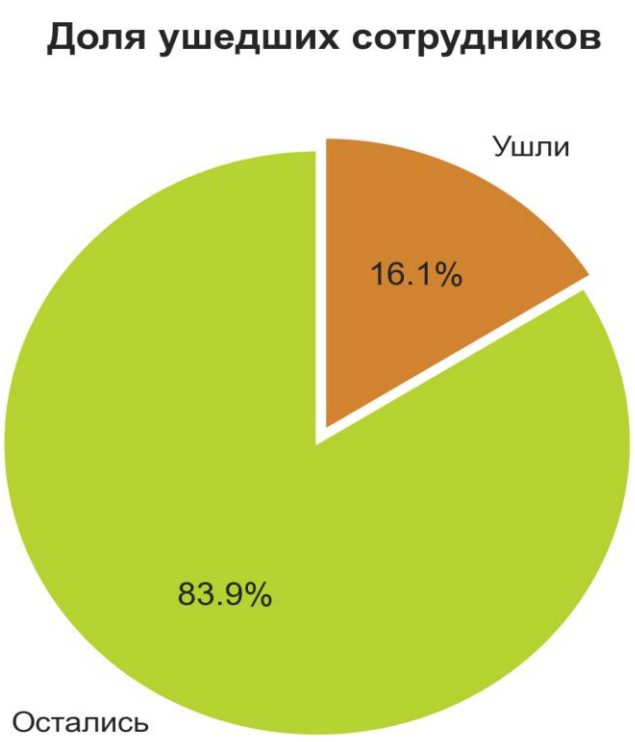
Признак	Что означает	Как создан
Generation	X, Y, Z	На основе года рождения
Season_of_Birth	Зима/Весна/Лето/Осень	На основе месяца рождения
Overall_Satisfaction	Средний индекс 5 шкал	JobSat + EnvSat + RelSat + WLB + Involv
Satisfaction_Level	Low / Medium / High	Категоризация индекса



EDA

EDA: общая картина оттока

Масштаб проблемы



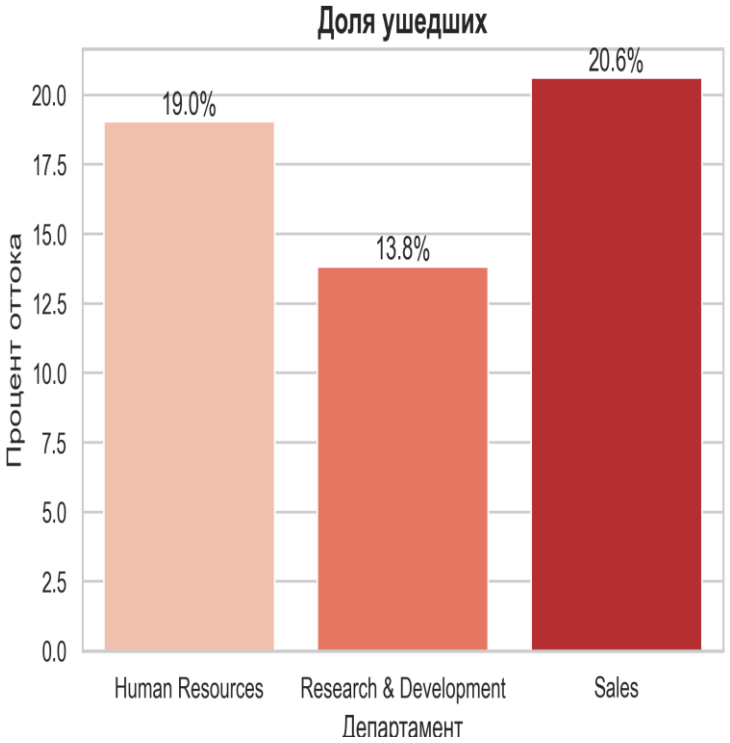
Ключевые факторы:

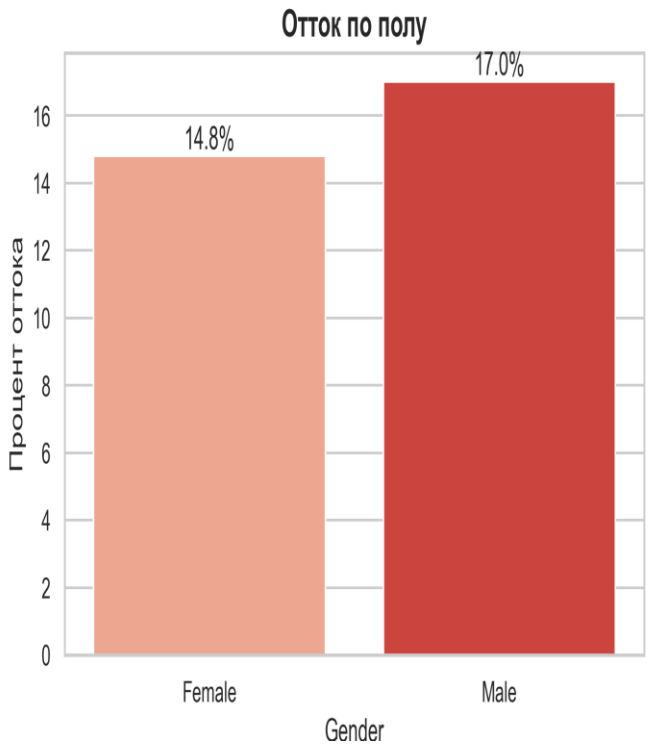
- Ушли: **237 сотрудников**
- Остались: **1233 сотрудника**
- Отток: **16.1%**

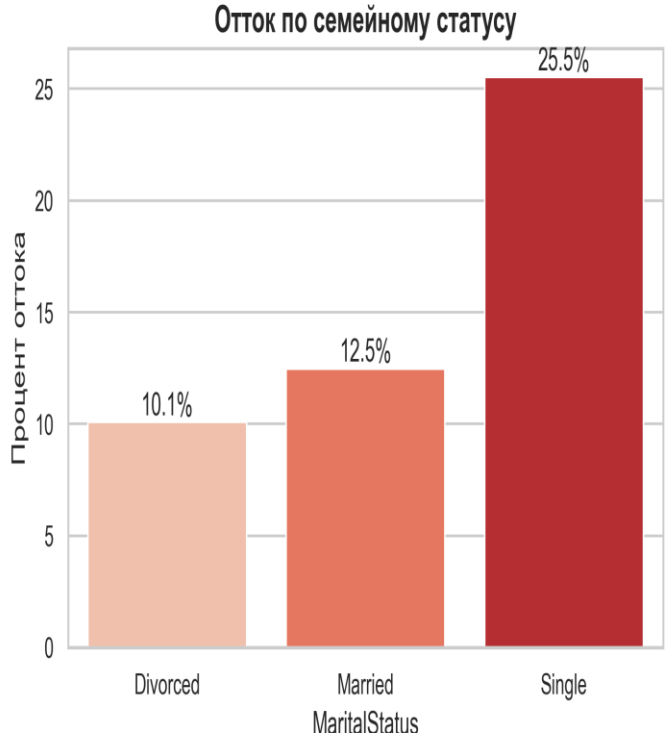
EDA: кто уходит

Портрет уходящего сотрудника

- **По полу:** мужчины 17%, женщины 14.8%
- **По семейному положению:** одинокие 25.5% vs женатые 12.5% vs разведённые 10.1%
- **По возрасту:** самый высокий отток до 28 лет
- **По департаменту:** Sales 20.6%, HR 19.0%, R&D 13.8%



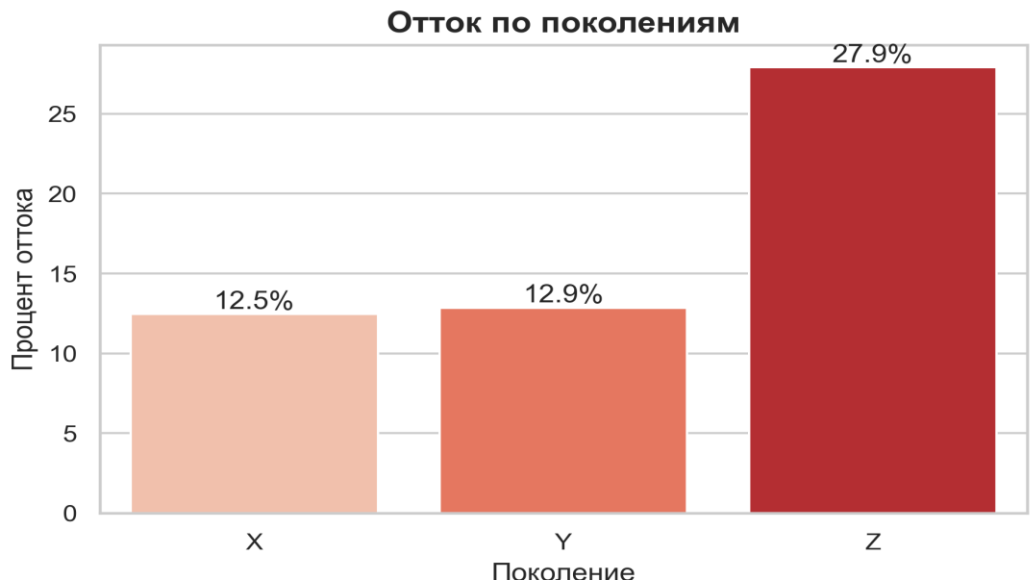


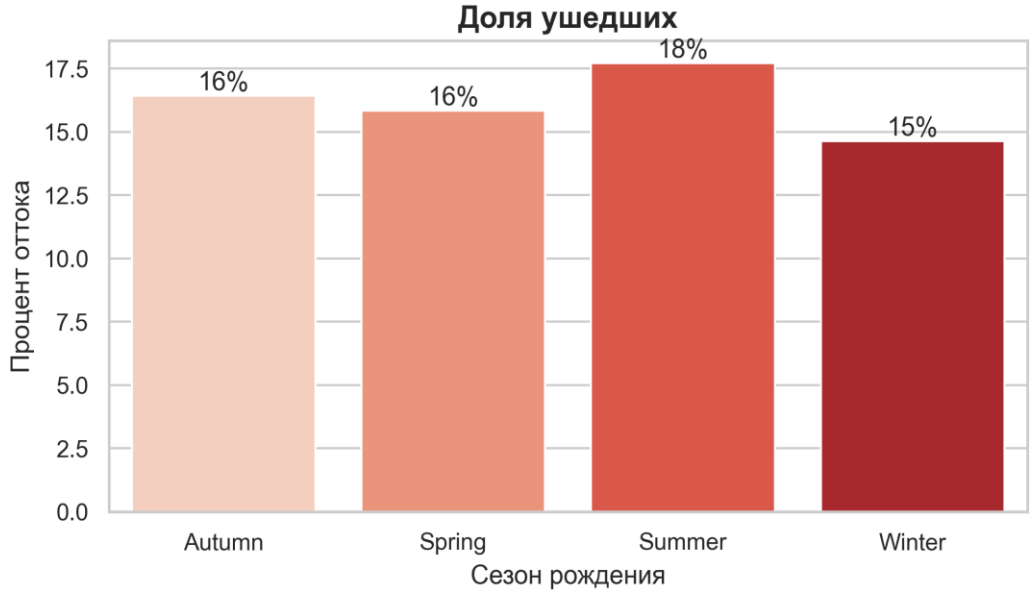


EDA: поколенческий и сезонный слои

Поколение Z — главный источник оттока

- X: 12.5%
- Y: 12.9%
- **Z: 27.9%** ← в 2 раза выше





EDA: комбинированные среды

Кто в зоне максимального риска

Топ-3 группы по оттоку:

- Одинокие женщины Z **- 43.8%**
- Одинокие мужчины Z **- 39.8%**
- Одинокие мужчины X - **27.9%**

Группы минимального риска:

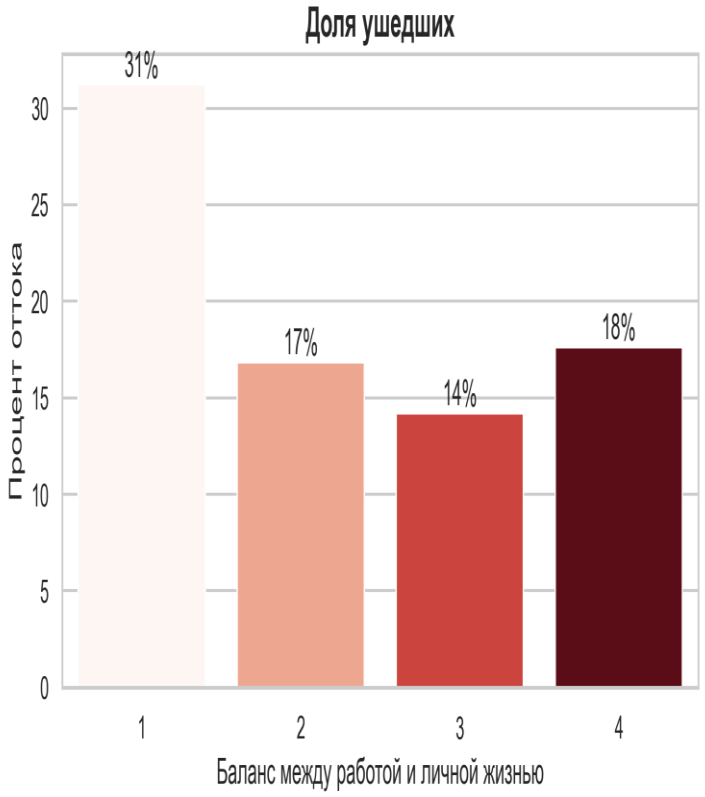
- Разведённые женщины всех поколений (< 12%)
- Женатые мужчины X и Y (< 12%)

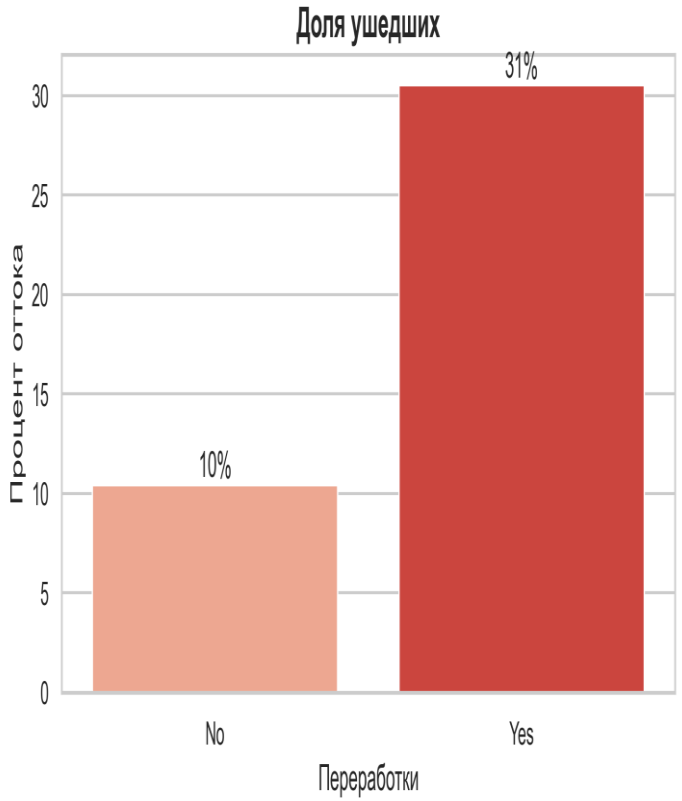


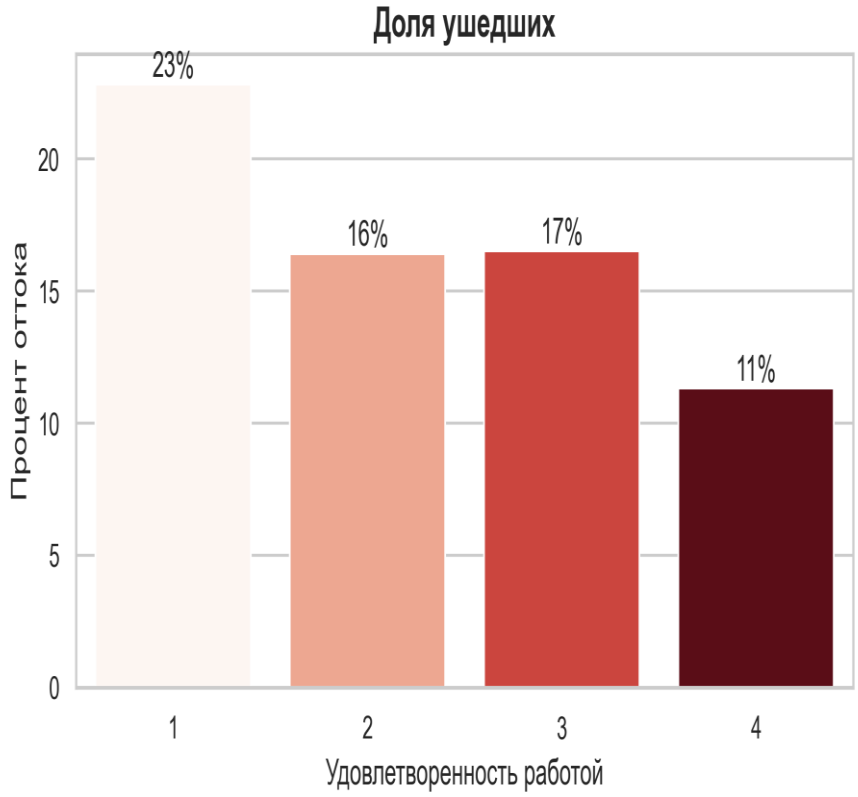
EDA: почему уходят

Поведенческие факторы – ключевые для оттока

- **Переработки: ключевой фактор оттока** - 31% - в 3 раза чаще, чем без них
- **Удовлетворенность:** с низким уровнем 23%
- **Баланс:** с низким уровнем 31%



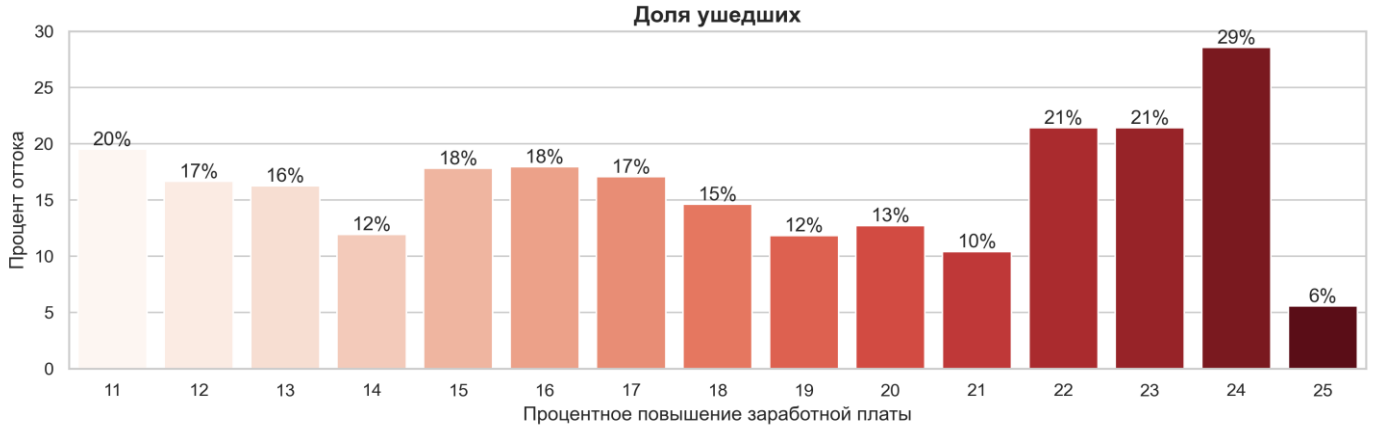


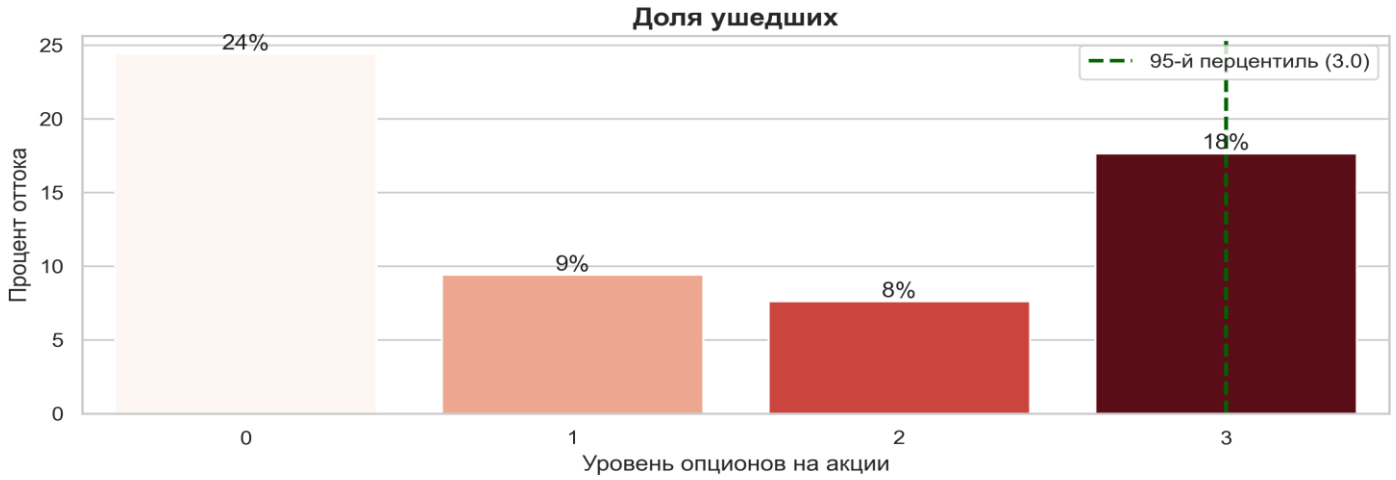


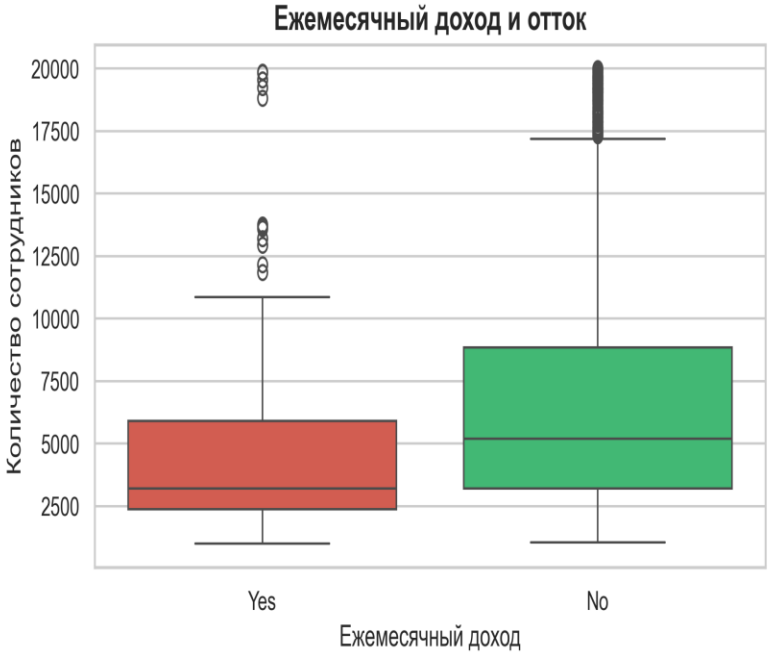
EDA: почему уходят

Материальная составляющая

- Уровень опционов на акции: **ключевой фактор**
- Без опционов: **24% (в 2-3 раза больше отток)**
- Ежемесячный доход: **слабо влияет**









EDA

Ключевые инсайты

- **Поколение Z** уходит чаще всех - 27.9% против 12.5% (X) и 12.9% (Y).
- **Молодые сотрудники (до 28 лет)** — основная группа риска.
- **Одинокие уходят чаще** — 25.5% против 12.5% (женатые) и 10.1% (разведённые).
- **Не имеющие опционов на акции** — 24.0% против 9 и 8% (в 3 раза выше)
- **Sales и HR** — «горячие точки» — 20.6% и 19.0% оттока.
- **Human Resources и Technical Degree** — сферы образования с самым высоким оттоком (25.9% и 24.2%).
- **Гипотеза о сезонности не подтвердилась** — сезон рождения не влияет на отток.
- **Степень удовлетворённости** распределена равномерно между поколениями.
- **Степень удовлетворённости** и **Переработки** являются ключевыми предикторами оттока.



Моделирование

Подход к моделированию

Методология

Подход:

- Классическая модель (Classic) - только демография, структура, компенсация и стаж.
- Расширенная модель (Extended) - классические признаки + поведенческий, поколенческий и сезонный слои.

Для каждой группы обучены шесть моделей:

- Logistic Regression
- Random Forest
- XGBoost
- LightGBM
- CatBoost
- **SVM** ← победитель

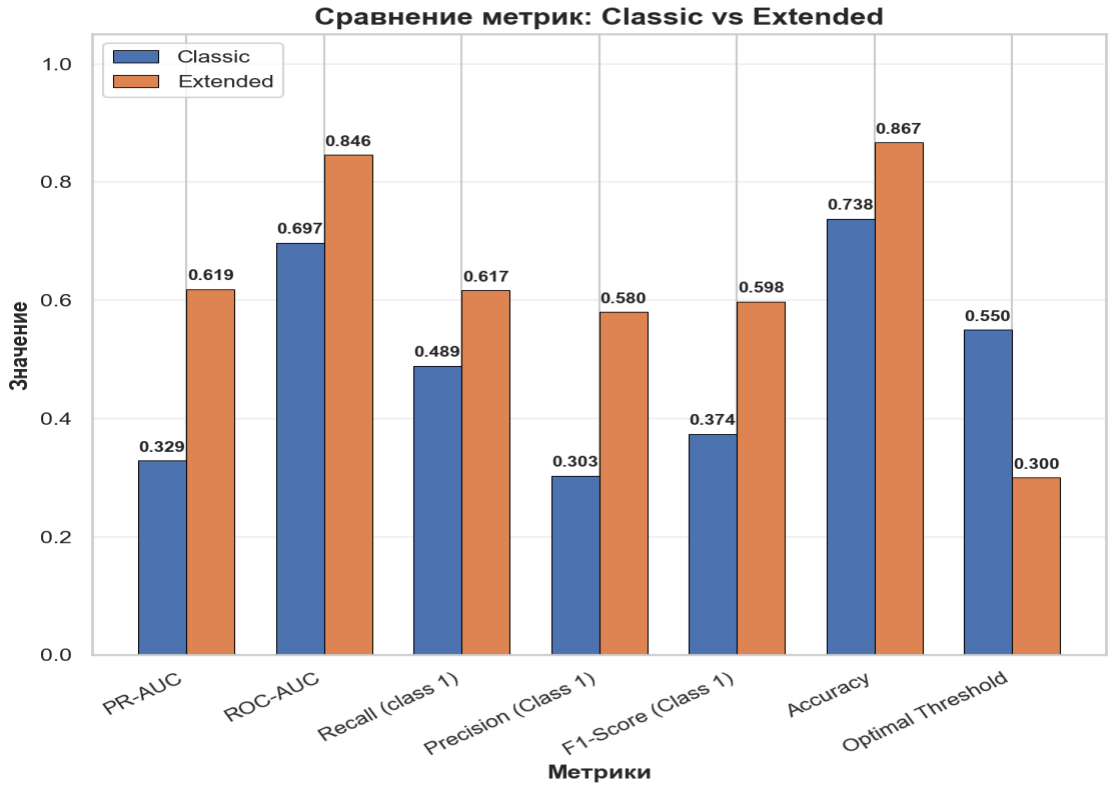
Методология:

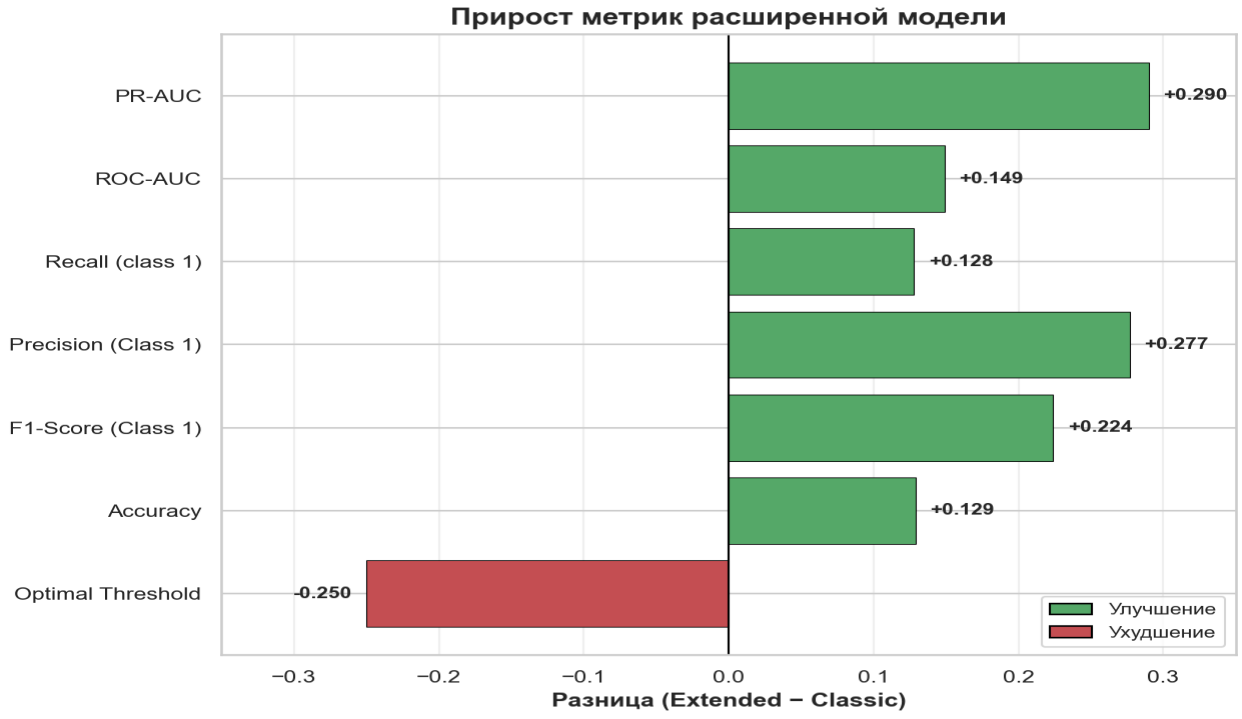
- Кросс-валидация: StratifiedKFold (n_splits=5)
- Оптимизация: GridSearchCV по метрике average_precision (PR-AUC)
- Порог классификации подбирается на тестовой выборке (диапазон 0.20–0.60)
- Учёт дисбаланса: class_weight='balanced', scale_pos_weight, auto_class_weights
- Препроцессинг: ColumnTransformer с раздельной обработкой числовых, порядковых, номинальных и бинарных признаков

Сравнение моделей

Расширенная модель побеждает

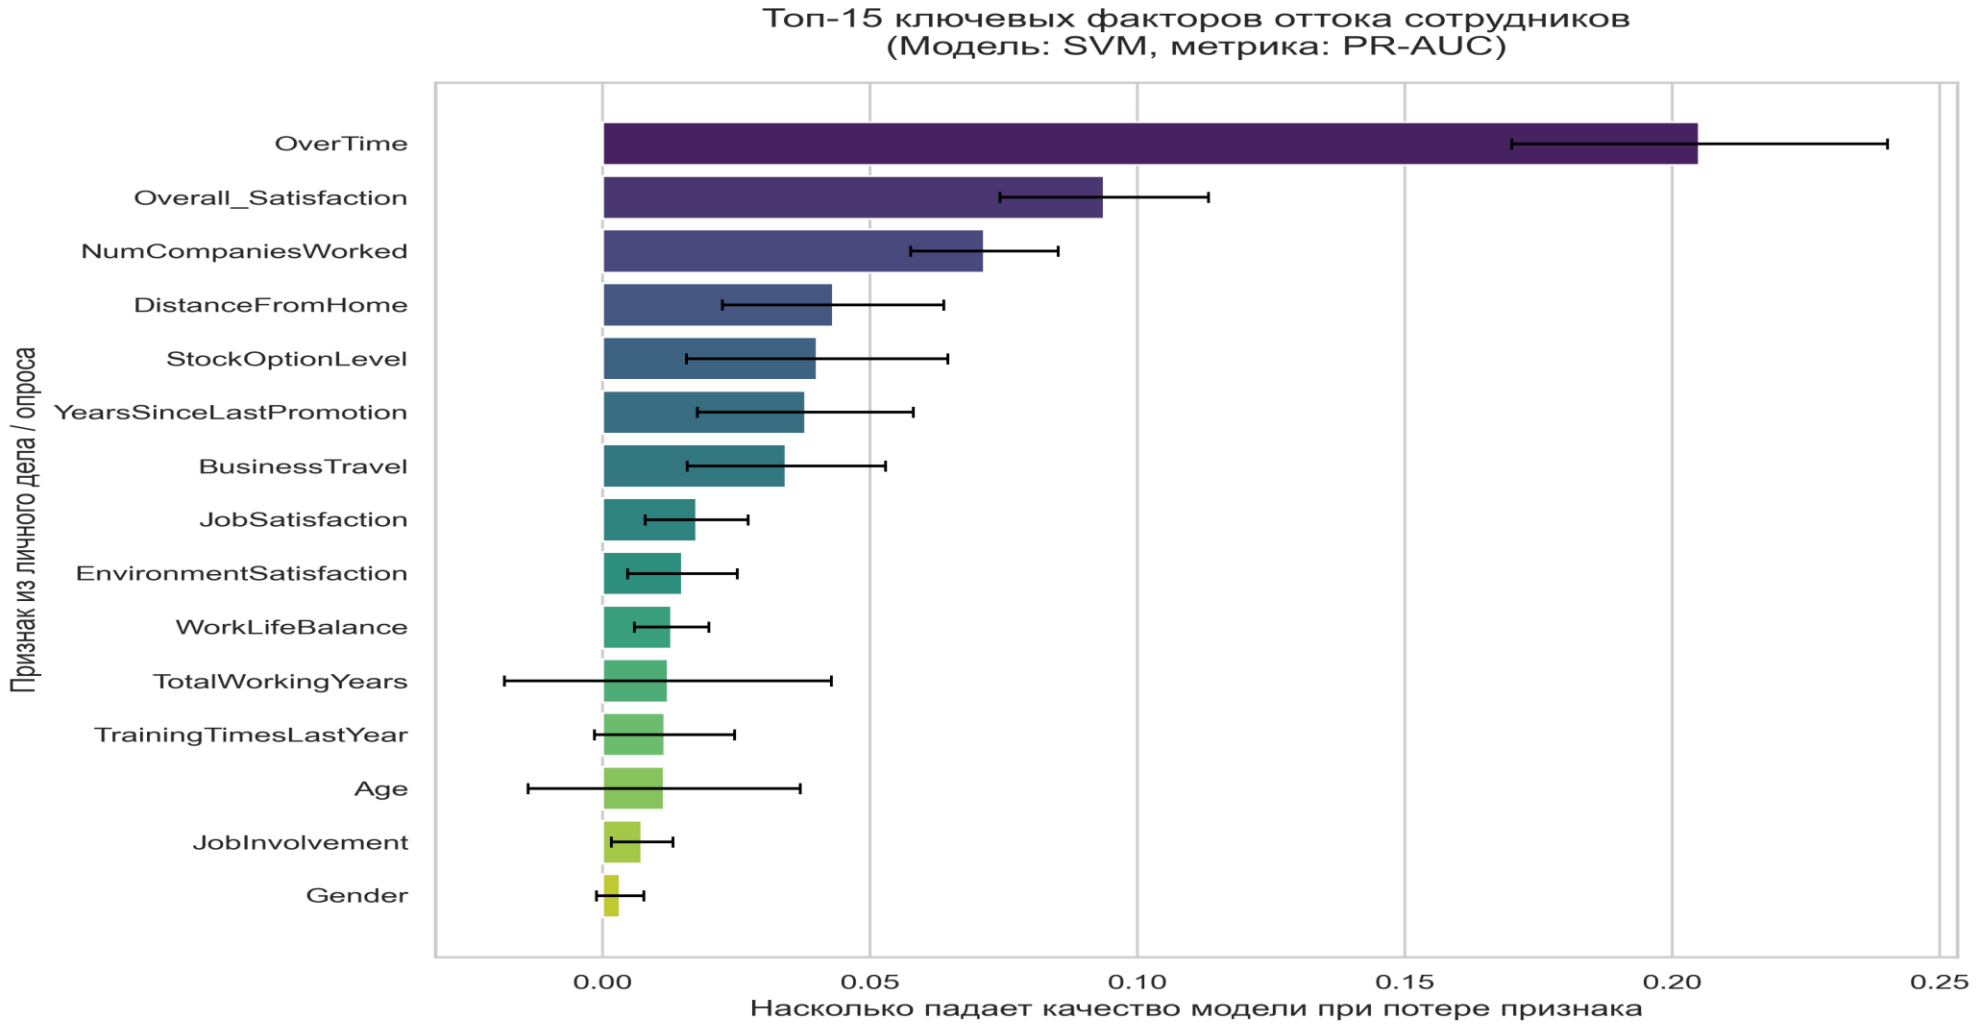
Метрика	Classic	Extended	Прирост
ROC-AUC	0.697	0.846	+0.149
PR-AUC	0.329	0.619	+0.290
F1 (attrition)	0.374	0.598	+0.224
Recall (attrition)	0.489	0.617	+0.128
Precision (attrition)	0.303	0.580	+0.277
Accuracy	0.738	0.867	+0.129





Feature Importance

Что влияет на отток сильнее всего



Итоговые метрики

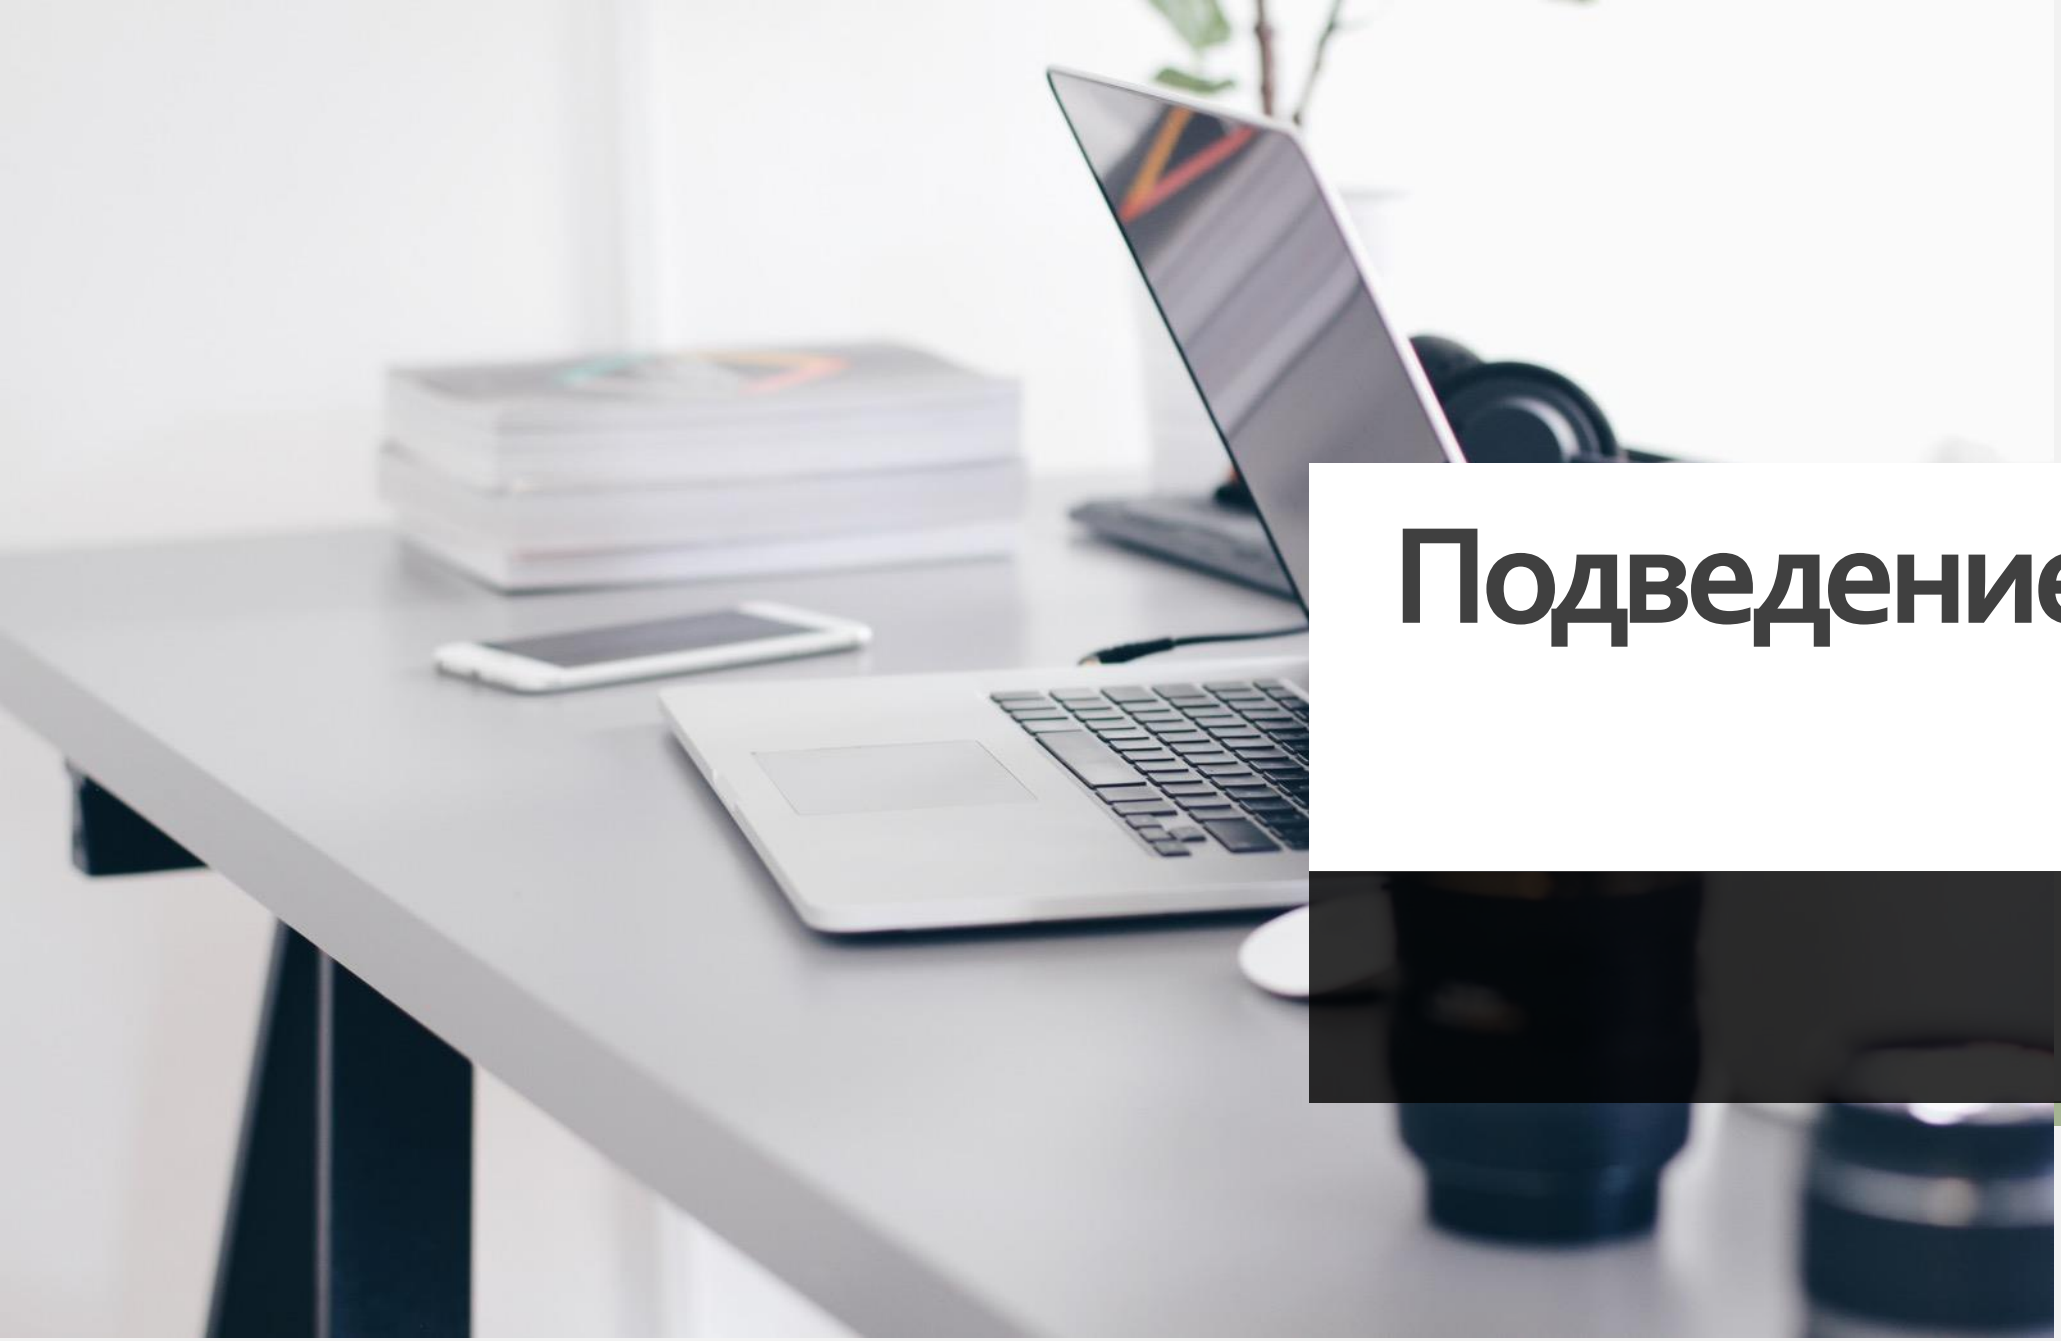
Финальные показатели модели

Итоговая модель: SVM

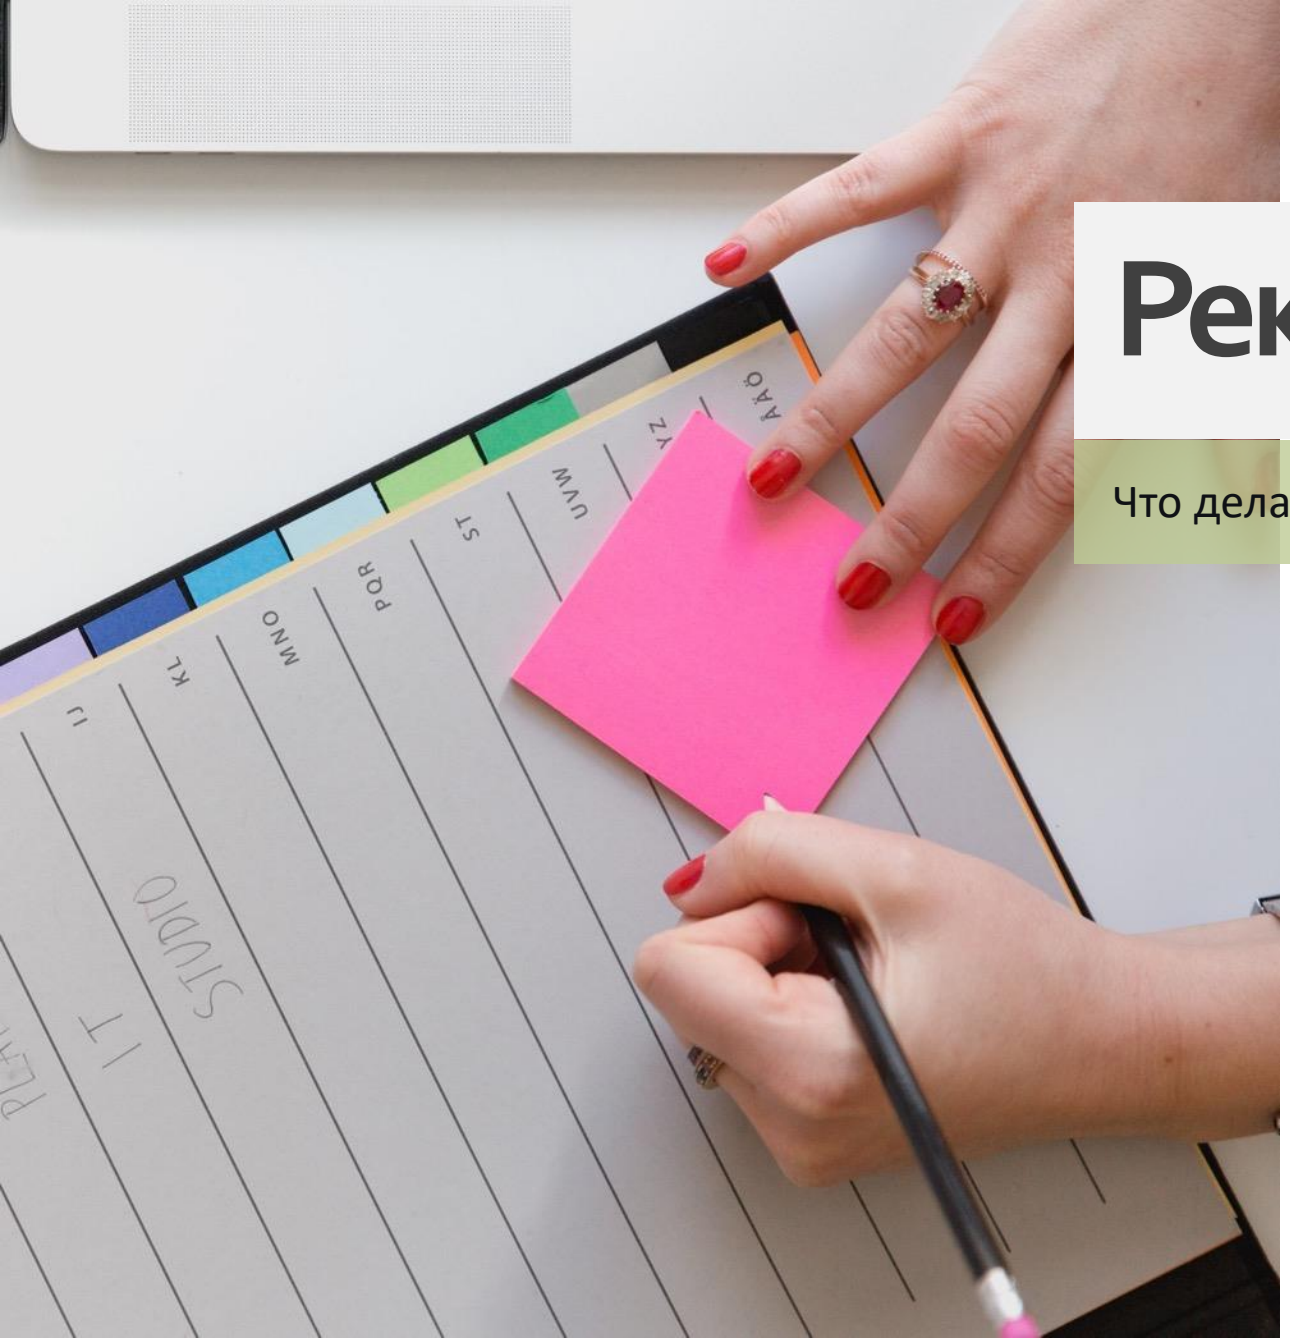
Порог классификации: 0.30

Метрика	Значение
ROC-AUC	0.846
PR-AUC	0.619
F1 (attrition)	0.598
Recall (attrition)	0.617
Precision (attrition)	0.580
Accuracy	0.867





Подведение итогов



Рекомендации для HR

Что делать бизнесу

1.Борьба со сверхурочной работой (OverTime)
- Аудит нагрузки в Sales и HR
- Ограничение переработок на уровне политики

2.Программа удержания поколения Z
- Менторство от старших коллег
- Прозрачный карьерный трек на 6-12 месяцев
- Быстрый онбординг

3.Работа с вовлечённостью
- Ежеквартальные пульс-опросы
- Программы признания достижений
- Больше автономии в решениях

4.Развитие карьеры
- Performance review = разговор о будущем
- Инвестиции в обучение

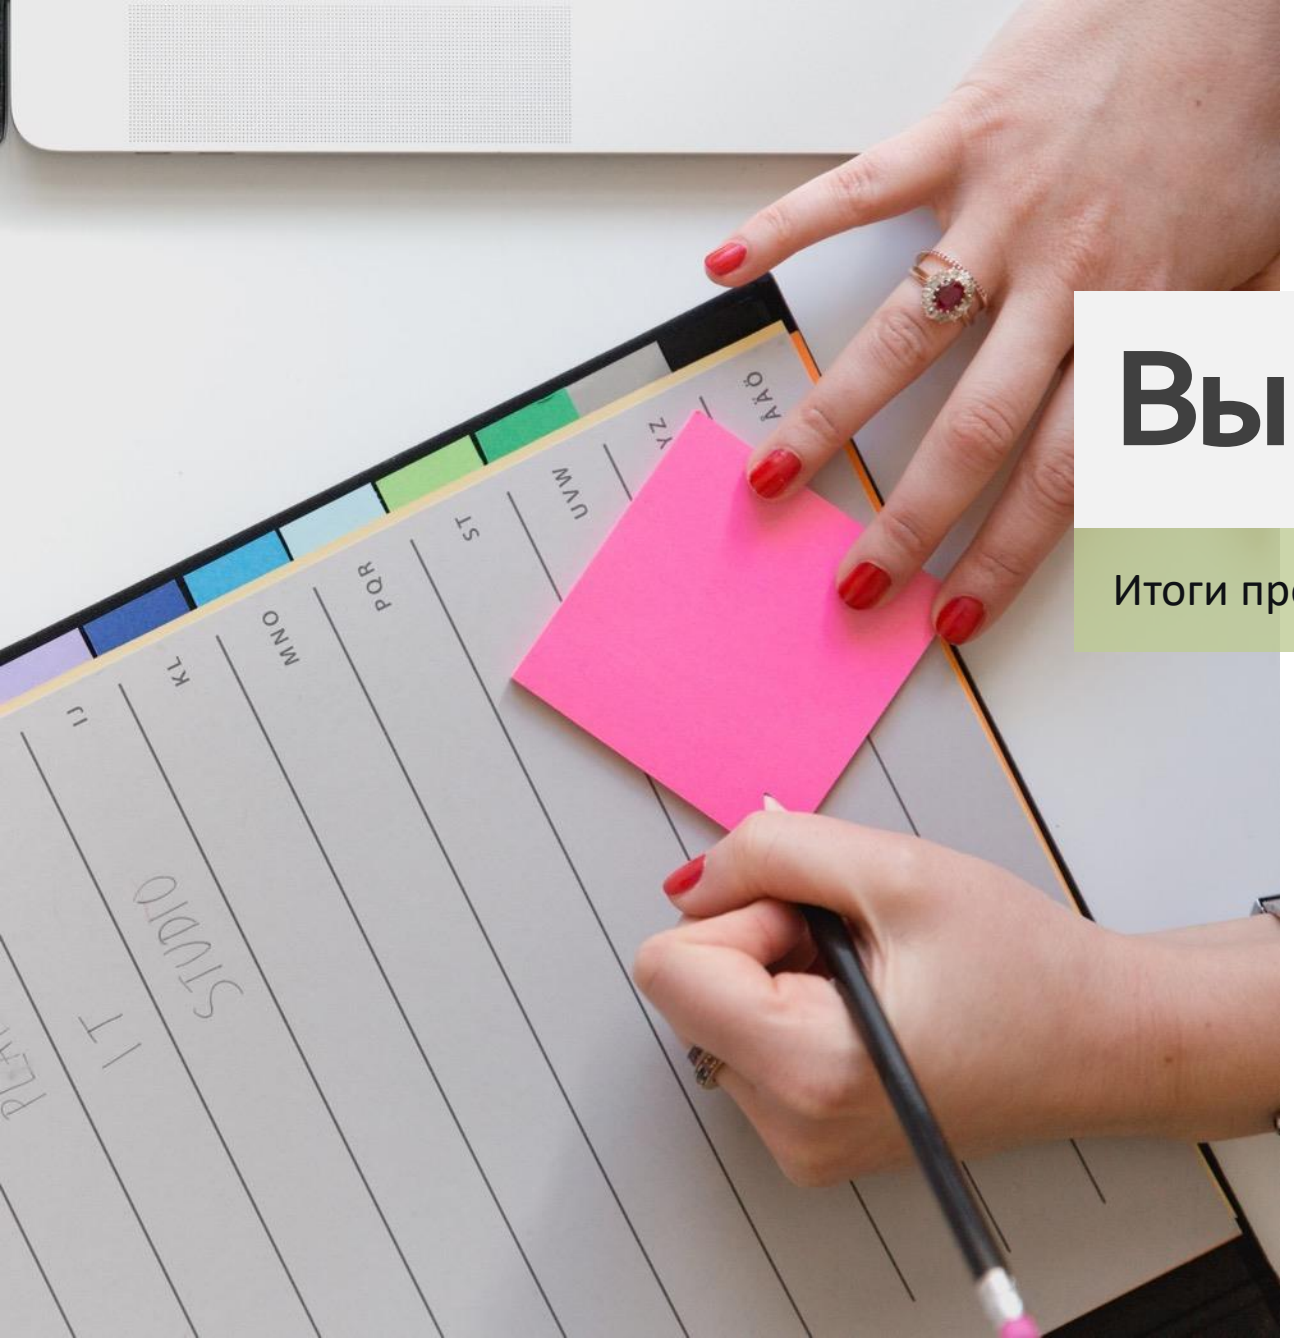
5.Фокус на «горячие точки»
- Exit-интервью в Sales и HR
- Отдельные программы для одиноких молодых сотрудников

- **Ограничения:**
- Датасет синтетический, выводы могут не переноситься 1-в-1
- Сезонный признак сгенерирован, реальная сезонность не проверена
- Год рождения условный (использован текущий год)
- **Что можно улучшить:**
- Получить реальные данные о датах рождения
- Добавить временной ряд (динамика оттока за 2-3 года)
- Внедрить текстовый анализ exit-интервью (NLP)
- Провести A/B-тест программы удержания



Ограничения и развитие

Честно об ограничениях

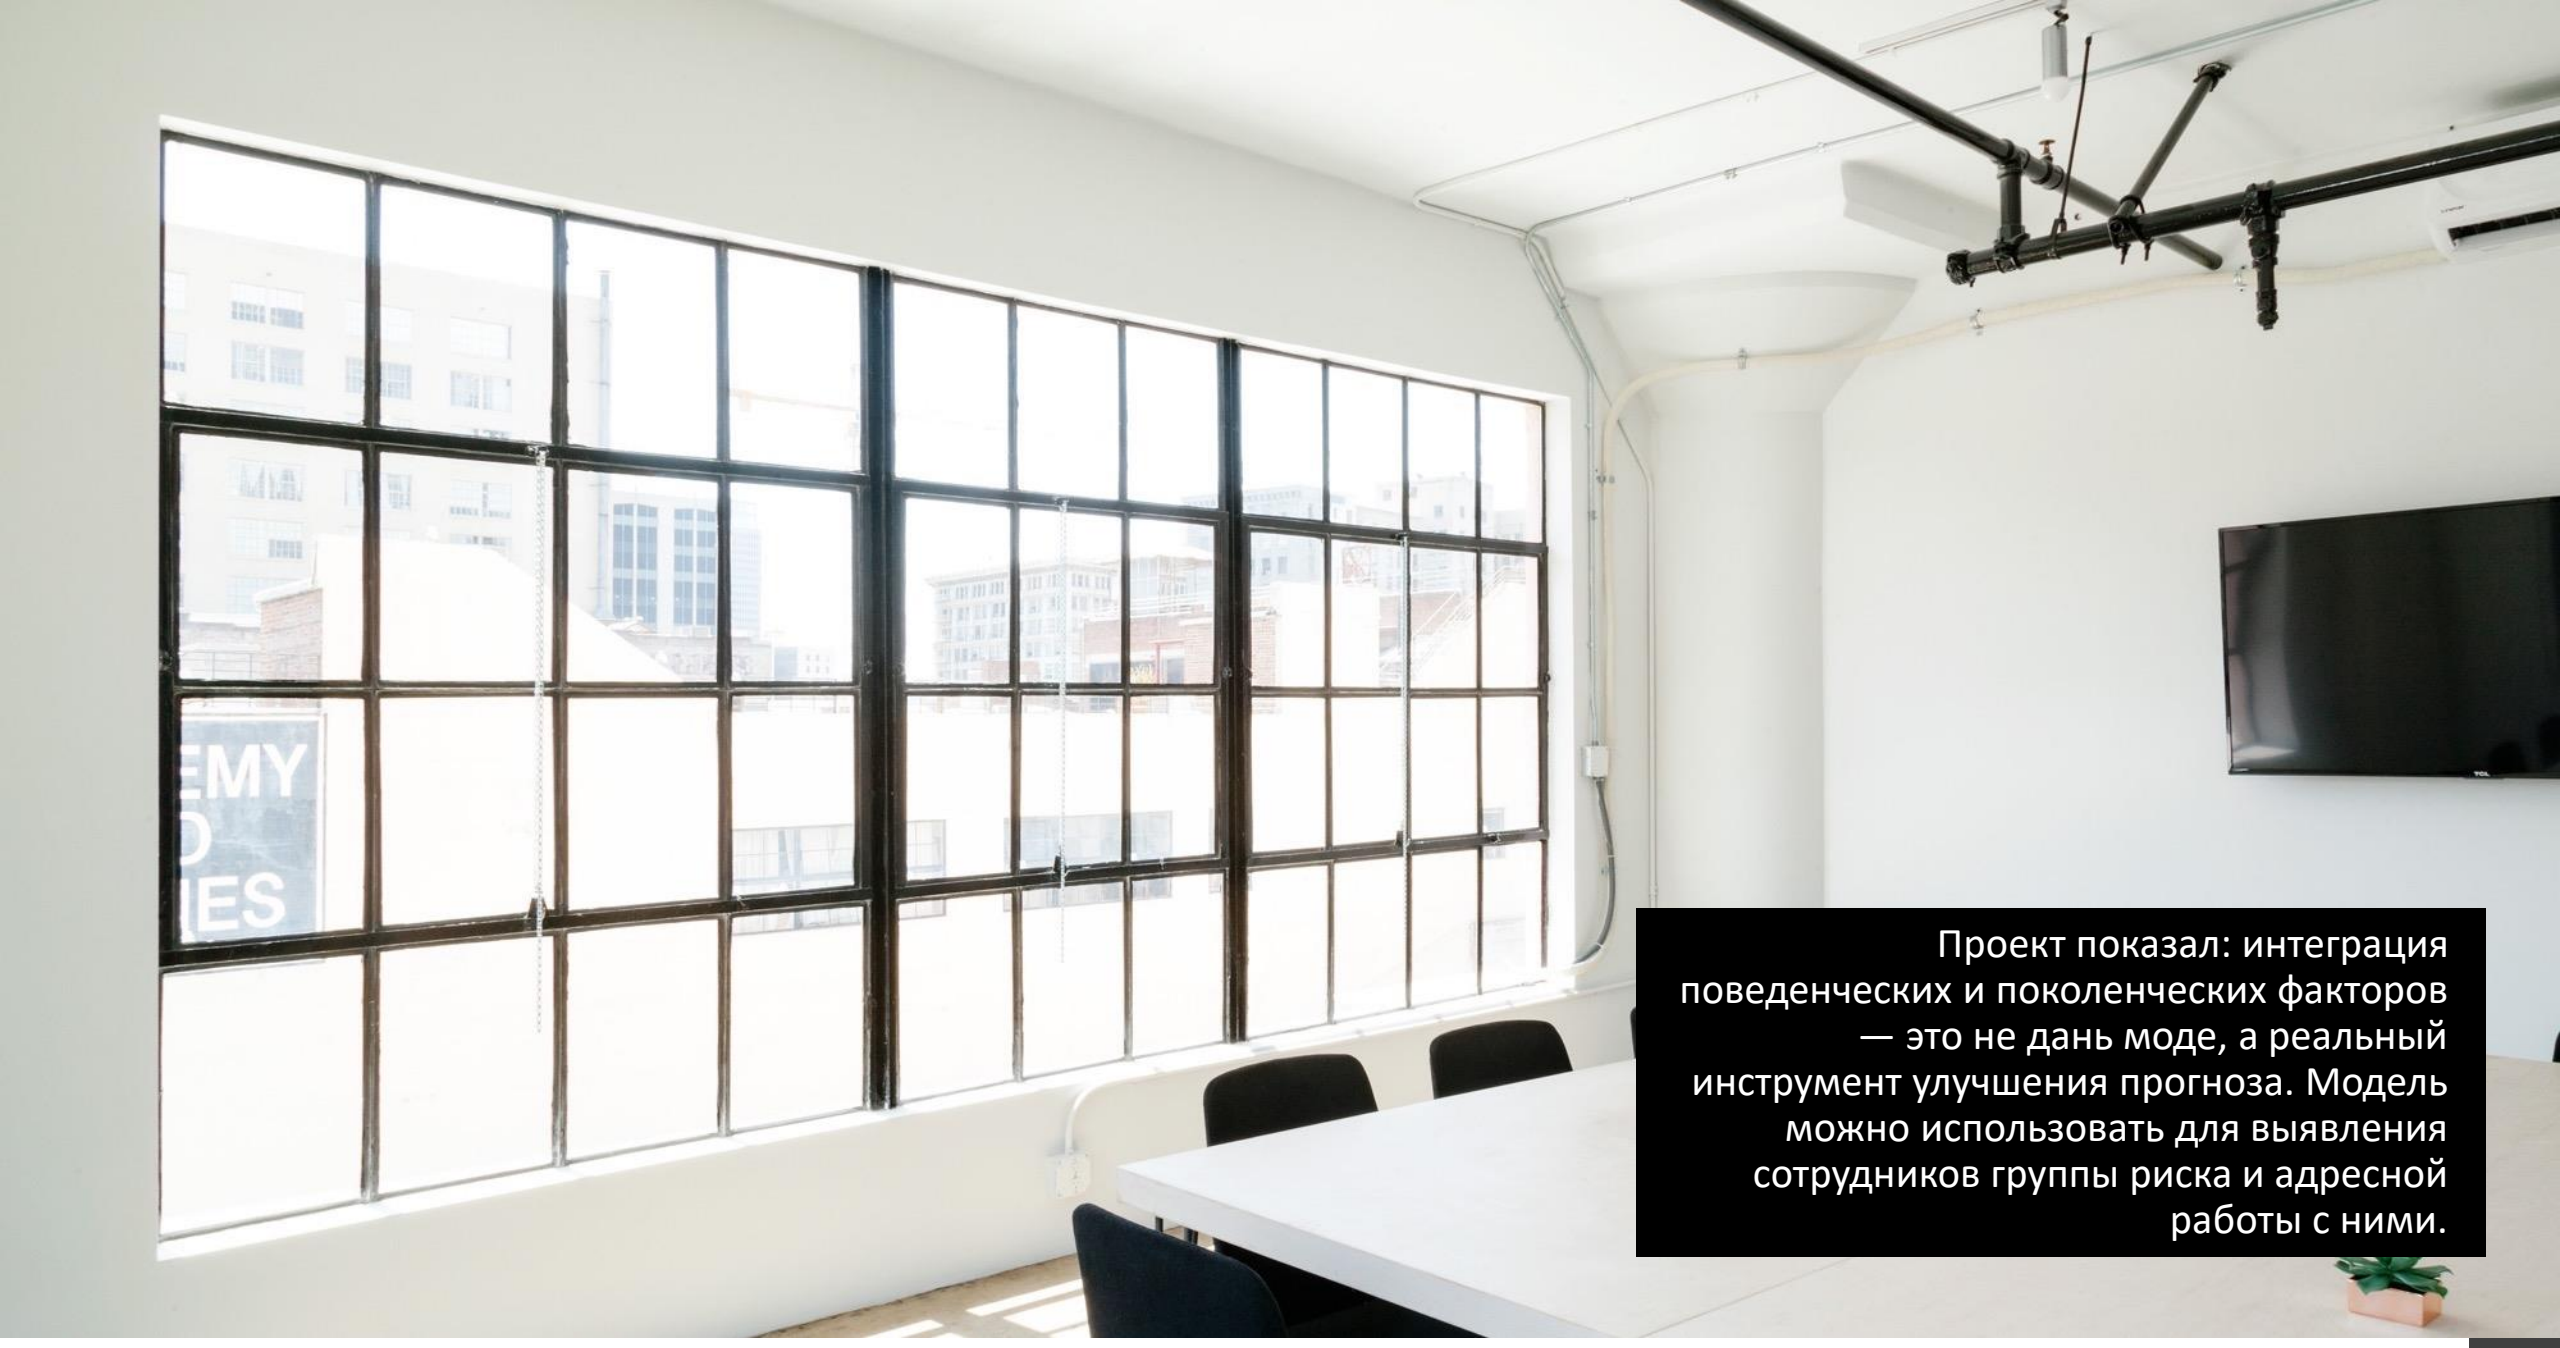


Выводы

Итоги проекта

4 ключевых вывода:

1. **Поколенческий слой работает.** Поколение Z уходит в 2 раза чаще — гипотеза подтверждена.
2. **Расширенная модель лучше классической.** Прирост по всем ключевым метрикам.
3. **OverTime и Overall_Satisfaction — главные драйверы.** Зарплата важна, но не решает всё.
4. **Практическая ценность.** Модель выявляет конкретные группы риска для HR-программ.



Проект показал: интеграция поведенческих и поколенческих факторов — это не дань моде, а реальный инструмент улучшения прогноза. Модель можно использовать для выявления сотрудников группы риска и адресной работы с ними.



Спасибо за внимание!

Надежда Володина
nn_volodina@mail.ru

Репозиторий

Ссылка на дашборд